АНАЛИТИЧЕСКИЙ ОТЧЁТ

Вероятности исходов футбольных матчей

Содержание

Задача и время прогноза 2

Источник и подготовка данных 2

Лиги и домашнее преимущество 2

Признаки до начала матча 3

Нейросеть и расширяющееся окно 3

Простые ориентиры 4

Качество прогноза 4

Вероятности и ошибки исходов 5

Неопределённость результата 6

Перерыв в сезоне 2019/20 6

Прогнозы матчей и ожидаемые очки 6

Насколько точно получаются очки команд 6

Насколько точно получаются места 8

Сравнение по очкам и местам 8

Турнирные таблицы сезона 2019/20 9

Выводы 11

Словарь данных 11

Источники 12

Воспроизведение 13

Нейросеть TensorFlow/Keras прогнозирует победу хозяев, ничью и победу гостей до начала матча. Используется архив Understat по пяти лигам за 2014/15–2019/20. Модель ежегодно обучается заново на всей завершённой истории.

Задача и время прогноза

Для каждой встречи нужны три вероятности, сумма которых равна единице. Они позволяют учитывать неопределённость исхода и рассчитывать ожидаемые очки команд. Прогноз строится на начало календарного дня. Результаты встреч этого дня добавляются в историю со следующей даты.

Единица наблюдения — сыгранный матч. Целевая переменная равна 0 при победе хозяев, 1 при ничьей и 2 при победе гостей. Все матчи одного дня используют одинаковую границу доступной информации.

Источник и подготовка данных

Первичный поставщик — Understat; таблицы получены из закреплённой версии публичного зеркала Mark Wilkins. В анализ входят 10,855 сыгранных матчей АПЛ, Ла Лиги, Бундеслиги, Серии А и Лиги 1. Период простирается с 2014-08-08 по 2020-08-02.

Исключена 101 строка без сыгранного результата, преимущественно отменённые встречи Лиги 1. Проверяются уникальность ID, конечные неотрицательные голы и xG, даты и состав лиг. В архиве 465 матчей хотя бы с одной командой, имеющей менее пяти предыдущих игр в доступной истории.

Текущие голы и xG используются после завершения матча. Готовые `forecast.w/d/l` поставщика исключены из входов, поскольку их доступность до игры не подтверждена. Даты читаются в календарной шкале источника. Архив является поздним снимком; историю исправлений xG и дат по нему восстановить нельзя.

Лиги и домашнее преимущество

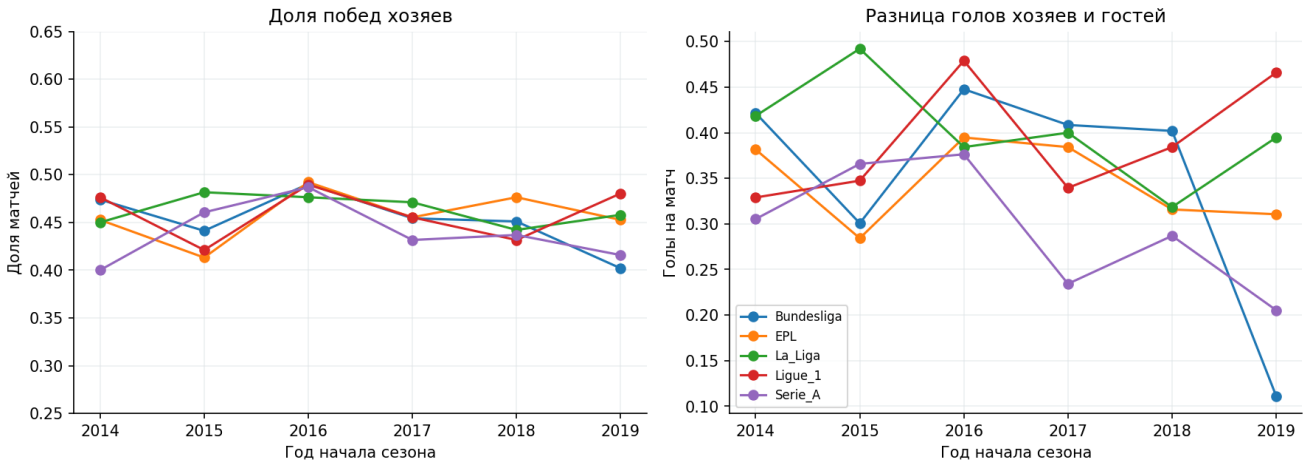


Рис. 1: Домашнее преимущество

Сравниваются доля домашних побед и разница голов хозяев и гостей на матч. Показатели рассчитываются отдельно для лиги и сезона. Такое представление учитывает разные размеры чемпионатов. Сезон Лиги 1 2019/20 завершён досрочно; для него учитываются сыгранные встречи.

Графики описывают результативность дома и в гостях. На межсезонные различия влияют состав клубов, календарь и условия проведения матчей. Все агрегаты доступны в таблице лиг и сезонов[1].

[1] Файл в исходном проекте: `reports/tables/league_seasons.csv`

Признаки до начала матча

Для хозяев и гостей используются средние голов, xG за и против и очков за последние 5 и 10 встреч. Дополняют их число дней отдыха, число матчей за 14 дней, домашняя и гостевая история и рейтинг Elo. Число предыдущих встреч ограничено 100, отдых — 60 днями. Отдельно сохраняется доступность истории.

История привязана к лиге и ID клуба. Названия и идентификаторы служат соединению записей; лига входит в сеть как категория. В матрице нет будущих итогов сезона и результата прогнозируемой игры. Тесты изменяют текущие и будущие результаты и проверяют неизменность более ранних признаков.

Пустая история заполняется медианами обучения и получает индикатор пропуска. Масштабы числовых признаков и категории лиг определяются заново внутри каждого обучающего окна. Для нового клуба Elo начинается с 1500.

Нейросеть и расширяющееся окно

Итоговая модель усредняет вероятности двух сетей с одинаковыми скрытыми слоями 32/16 и разными seed — 20261104 и 20261121. Используются ReLU, L2=0.005 и Dropout=0.2. Три выходных логита преобразуются softmax в П1/Х/П2. Adam работает с learning rate 0.001, размер пакета 256, функция потерь — cross-entropy.

Перед началом сезона последний завершённый сезон временно выделяется для ранней остановки. На более ранних сезонах оцениваются преобразования и веса; остановка отслеживает log loss, максимум 100 эпох, patience=10. Затем сеть и преобразования обучаются с нуля на всей доступной истории с выбранным числом эпох. Две сети получают собственное число эпох.

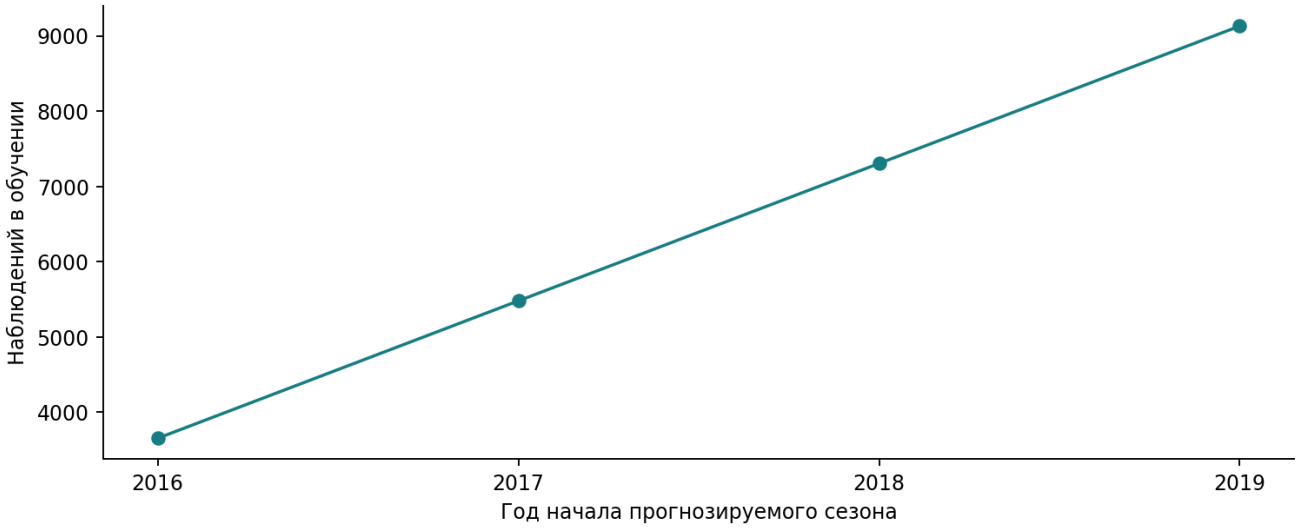


Рис. 2: История обучения

Период	Обучение	Прогноз	Эпохи двух сетей
2016	3652	1826	26 / 25
2017	5478	1826	51 / 26
2018	7304	1826	23 / 46
2019	9130	1725	28 / 12

Проверочные сезоны 2017/18 и 2018/19 используют только более ранние результаты. Для оценки 2019/20 сеть обучена на 9 130 матчах сезонов 2014/15–2018/19. Во время прогнозируемого сезона веса фиксированы, а входная история команд пополняется после завершённых дней. Вероятности берутся из среднего softmax двух сетей.

Простые ориентиры

Постоянный прогноз использует частоты П1/Х/П2. Elo обновляется после игрового дня с K=20 и домашней поправкой 70. На границе сезона сохраняется 75% отклонения рейтинга от 1500. Частоты исходов и параметр ничьей Elo оценены на сезонах 2014/15–2016/17; сам рейтинг продолжает обновляться по завершённым матчам.

Пуассоновский ориентир берёт геометрическое среднее прошлого xG атаки команды и xG обороны соперника с учётом дома/выезда. Командные средние сглаживаются пятью условными матчами к прошлому среднему лиги. Начальная лига содержит 20 условных матчей с 1.4 домашнего и 1.1 гостевого xG. Интенсивности ограничены диапазоном [0.1; 6], счёт перебирается от 0 до 30 голов, затем вероятности нормируются. Голы команд в этом ориентире предполагаются независимыми.

Качество прогноза

Основная метрика — log loss. Brier равен средней сумме квадратов ошибок трёх вероятностей. Accuracy — доля матчей, в которых наиболее вероятный исход совпал с фактом. Все модели оцениваются на одинаковых 1,725 матчах.

Модель	Матчи	Log loss	Brier	Accuracy
Частоты исходов	1725	1.07046	0.64767	0.44116
Elo	1725	1.00428	0.60004	0.51710
Пуассон по xG	1725	1.02579	0.61521	0.48986
Нейросеть	1725	0.99187	0.59131	0.51420

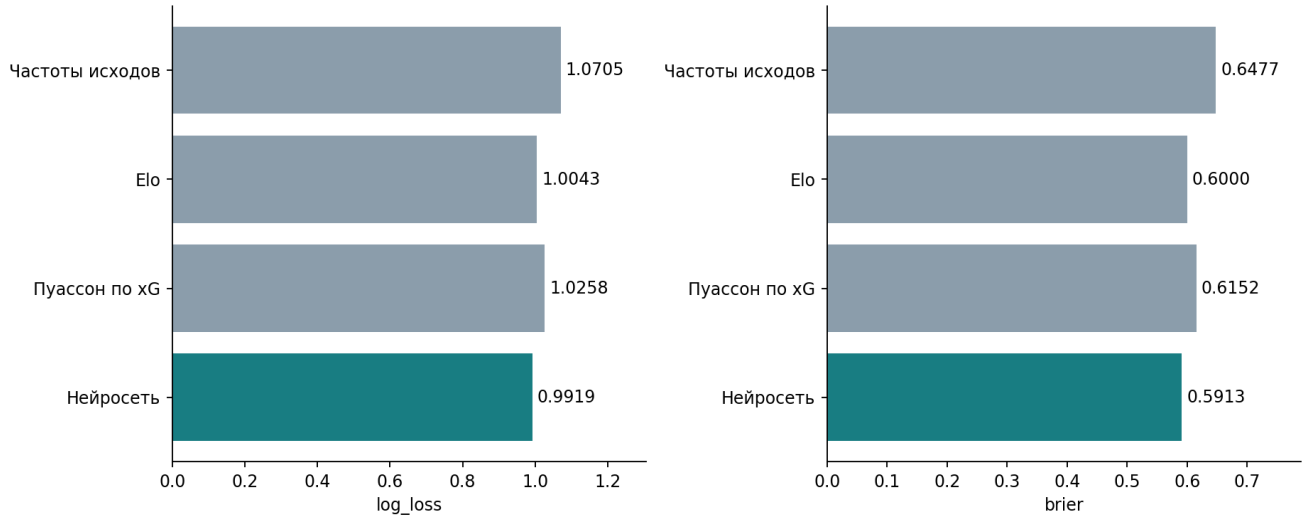


Рис. 3: Сравнение с ориентирами

Лига	Матчи	Log loss	Brier	Accuracy
Бундеслига	306	0.99556	0.59439	0.50654
АПЛ	380	0.97839	0.58139	0.51053
Ла Лига	380	1.00876	0.60541	0.49737
Лига 1	279	1.00092	0.59925	0.50538
Серия А	380	0.97882	0.57882	0.54737

Разрезы показывают качество отдельно по каждой лиге. При сравнении важны число матчей, баланс исходов и полнота истории новых команд.

Вероятности и ошибки исходов

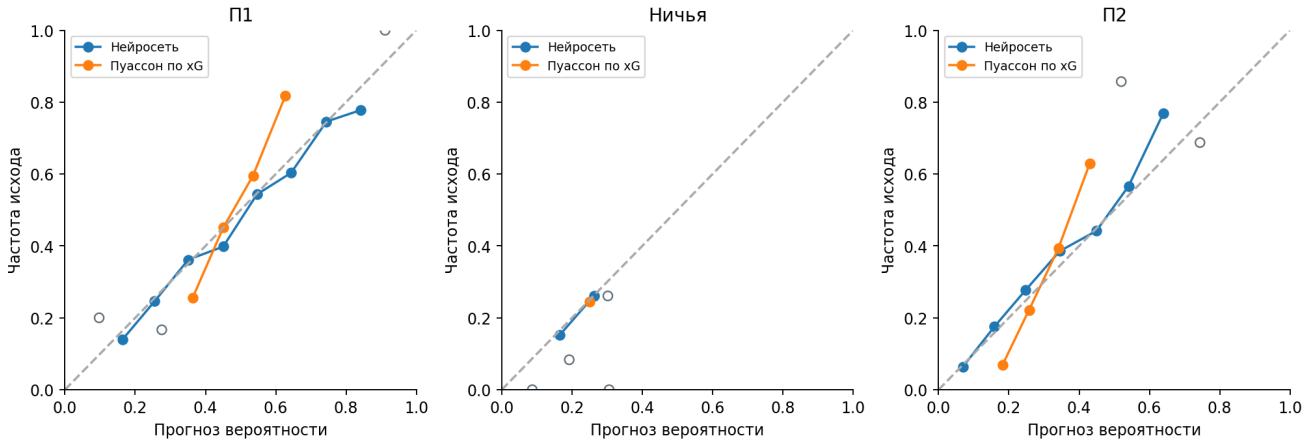


Рис. 4: Вероятности и частоты

Для каждого исхода прогнозы разбиты на интервалы шириной 0.1. Средняя вероятность сопоставлена с долей фактических исходов. Полые точки обозначают интервалы с менее чем 30 матчами. Это проверка вероятностей итоговой сети.

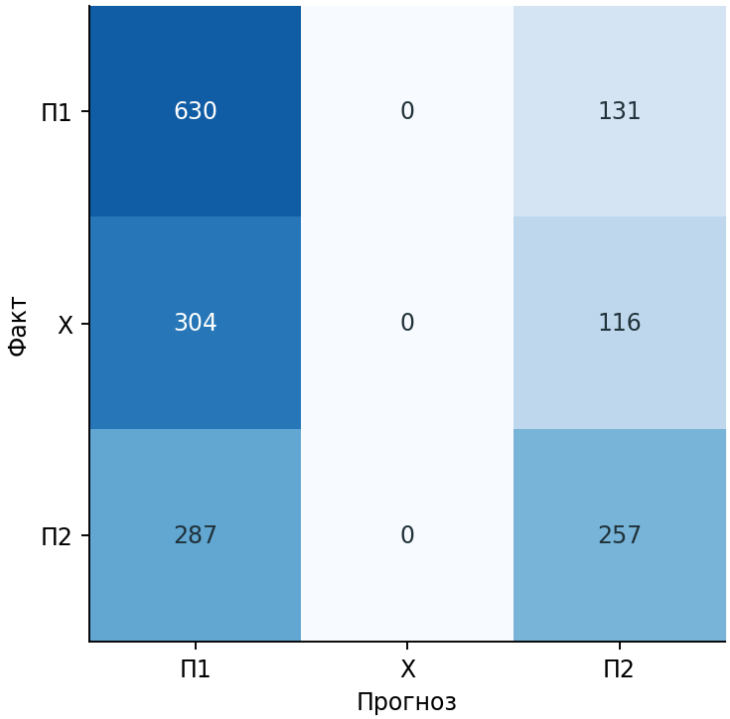


Рис. 5: Распределение ошибок

Ничья оказалась наиболее вероятным исходом в 0 матчах из 1725. Матрица отражает решение по максимуму вероятности; log loss использует весь вектор и чувствителен к уверенности прогноза.

Неопределённость результата

Ориентир	Разница log loss	Нижняя 95%	Верхняя 95%
Частоты исходов	-0.07859	-0.09533	-0.06216
Elo	-0.01241	-0.02066	-0.00375
Пуассон по xG	-0.03392	-0.04459	-0.02368

Разница равна log loss нейросети минус log loss ориентира. 95% интервалы рассчитаны 3 000 повторами парного бутстрэпа по календарным неделям. Все встречи одной недели остаются в одном блоке. Связи повторных игр клубов между неделями могут сохраняться; поправка на несколько сравнений не вводилась.

Перерыв в сезоне 2019/20

Модель	Период	Матчи	Log loss	Brier
Elo	До перерыва	1317	1.00945	0.60380
Elo	После перерыва	408	0.98757	0.58791
Пуассон по xG	До перерыва	1317	1.02911	0.61767
Пуассон по xG	После перерыва	408	1.01508	0.60725
Нейросеть	До перерыва	1317	1.00026	0.59746
Нейросеть	После перерыва	408	0.96477	0.57146

Первая группа включает даты до 15 марта 2020 года, вторая — с 15 мая. Лига 1 сезон не возобновила, поэтому состав лиг во второй группе отличается. Разрез показывает устойчивость ошибок в двух частях календаря; для объяснения различий потребовались бы посещаемость, составы и травмы.

Прогнозы матчей и ожидаемые очки

Дата	Хозяева	Гости	П1	Ничья	П2
2020-08-01	AC Milan	Cagliari	0.753	0.168	0.079
2020-08-01	Brescia	Sampdoria	0.361	0.284	0.355
2020-08-01	Juventus	Roma	0.622	0.230	0.148
2020-08-02	SPAL 2013	Fiorentina	0.319	0.273	0.408
2020-08-02	Sassuolo	Udinese	0.483	0.281	0.236
2020-08-02	Bologna	Torino	0.455	0.291	0.254
2020-08-02	Genoa	Verona	0.410	0.292	0.298
2020-08-02	Lecce	Parma Calcio 1913	0.488	0.269	0.243

Показаны исторические прогнозы последних матчей архива. Например, вероятность 0.6 означает оценку 60% для соответствующего исхода при доступной модели информации. Для каждой команды ожидаемые очки в матче равны $3 \times$ P(победа) + P(ничья).

Насколько точно получаются очки команд

Для каждой команды складываются ожидаемые очки всех сыгранных матчей сезона 2019/20. Каждый прогноз использует историю, доступную перед конкретной встречей. Таким образом оценивается сумма последовательных предматчевых прогнозов с обновлением формы команды по ходу сезона. Для прогноза всей таблицы на старте сезона потребуется отдельная проверка с информацией, доступной на эту дату.

Ошибка равна фактическим очкам минус расчётным. Плюс означает, что команда набрала больше ожидаемого, минус — меньше. Средняя абсолютная ошибка показывает обычный размер расхождения без взаимного погашения плюсов и минусов.

Лига	Команд	Средняя ошибка	Смещение	Ст. отклонение	Дисперсия
Все команды	98	5.18	0.07	6.71	45.06
Бундеслига	18	4.56	0.30	5.51	30.34
АПЛ	20	5.00	-0.01	6.43	41.30
Ла Лига	20	5.46	-0.43	7.39	54.66
Лига 1	20	4.88	0.12	6.48	42.01
Серия А	20	5.96	0.40	7.42	55.12

На 98 командах средняя абсолютная ошибка составляет **5.18 очка**, медианная — 4.14. RMSE равен 6.71 очка и сильнее учитывает крупные промахи. У 54 команд (55.1%) ошибка укладывается в 5 очков, у 87 (88.8%) — в 10 очков.

Дисперсия отклонений равна **45.06 очка²**, стандартное отклонение — 6.71 очка. Они описывают разброс ошибок между командами этого сезона. Дисперсия рассчитана как средний квадрат отклонения ошибки от её среднего с делением на число команд. Это характеристика наблюдаемого разброса, а интервал для очков отдельной команды требует моделирования неопределённости её матчей.

Среднее смещение всего +0.07 очка объясняется взаимной компенсацией ошибок. Например, Liverpool набрал 99 очков при расчёте 83.90, а Espanyol — 25 при расчёте 45.83. Для Espanyol ошибка достигает 20.83 очка. По таким случаям видно, почему одного среднего смещения недостаточно.

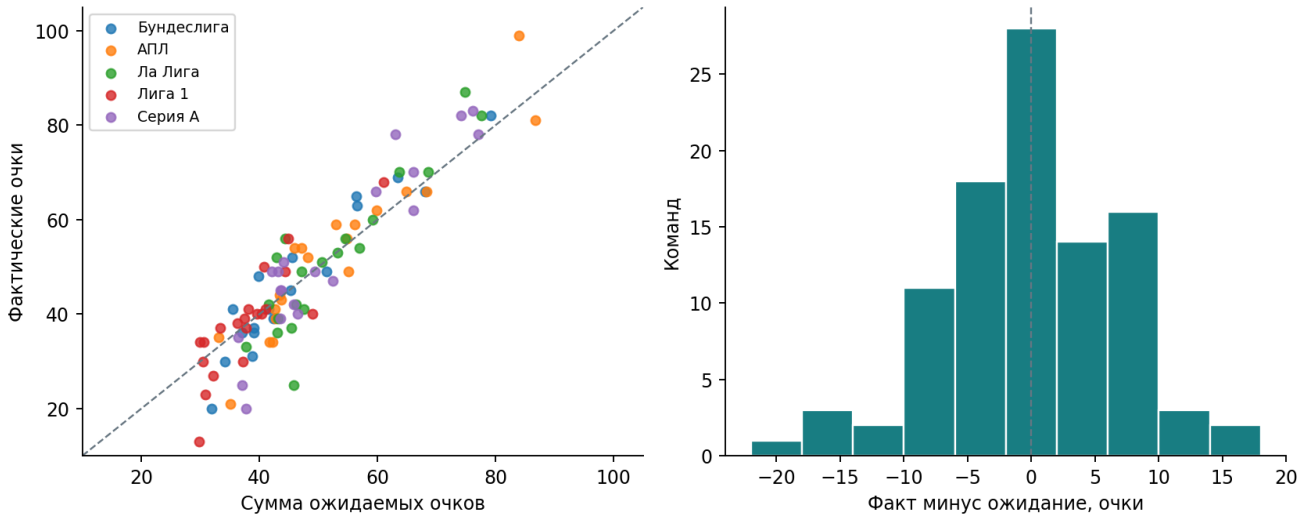


Рис. 6: Ожидаемые очки и ошибки команд

Каждая команда имеет одинаковый вес в общей строке. Бундеслига содержит 34 матча на клуб, АПЛ, Ла Лига и Серия А — 38, Лига 1 — 27–28. Если разделить абсолютное отклонение сезонных очков каждой команды на число её матчей, среднее по клубам составит 0.148 очка на матч. Так сравниваются расхождения накопленных очков с учётом длины сезона. Этот показатель сохранён отдельно по лигам в таблице ошибок.

Насколько точно получаются места

Расчётное место получается сортировкой команд по ожидаемым очкам внутри лиги. Во Франции сезон завершился досрочно, поэтому для сортировки используются ожидаемые очки за матч. Фактические места взяты из итоговых таблиц RSSSF с учётом дополнительных правил при равенстве очков. Число сыгранных матчей и набранные очки всех 98 команд сверены с результатами в датасете.

Разница мест равна расчётному месту минус фактическое. Например, +3 означает, что команда закончила сезон на три позиции выше расчёта. При одинаковых ожиданиях используется среднее из занятых мест. Порядок определяется до округления отображаемых очков. Место в таблице ожиданий — отдельный показатель, для среднего места по возможным исходам сезона нужна симуляция результатов матчей.

Лига	Ошибка в местах	Точное место	В пределах ±2	Максимум
Все команды	1.96	17	68	8.00
Бундеслига	1.22	5	15	5.00
АПЛ	1.40	2	16	5.00
Ла Лига	2.50	4	14	8.00
Лига 1	2.10	3	11	5.00
Серия А	2.50	3	12	7.00

Средняя ошибка равна **1.96 места**. Точное совпадение получилось у 17 из 98 команд (17.3%), отклонение не более двух мест — у 68 (69.4%). Наибольшая ошибка составляет 8 мест. Granada заняла 7-е место при расчётном 15-м, Osasuna — 10-е при 18-м.

Очки и места стоит смотреть вместе. Real Valladolid набрал 42 очка при ожидании 41.54, но расчётное 19-е место отличается от фактического 13-го на 6 позиций. В плотной части таблицы небольшое изменение очков заметно меняет порядок команд.

Лига	Чемпион	Лидер расчёта	Из топ-4	Из последних 3
Бундеслига	Bayern Munich	Bayern Munich	3	2
АПЛ	Liverpool	Manchester City	4	2
Ла Лига	Real Madrid	Barcelona	4	1
Лига 1	Paris Saint Germain	Paris Saint Germain	3	1
Серия А	Juventus	Atalanta	3	3

Лидер расчётной таблицы совпал с чемпионом в 2 из 5 лиг. Из двадцати мест в первых четвёрках совпали 17, из пятнадцати мест в последних тройках — 9. Последняя колонка сравнивает три нижних места каждой таблицы. В Бундеслиге 16-е место ведёт в стыковые матчи, а во Франции в этом сезоне вылетели две команды.

Сравнение по очкам и местам

Все модели используют один набор матчей. Для каждой заново складываются ожидаемые очки и строится своя таблица.

Модель	Ошибка в очках	RMSE очков	Ошибка в местах
Нейросеть	5.18	6.71	1.96
Частоты исходов	12.23	15.81	4.98
Elo	7.07	8.95	2.10
Пуассон по xG	9.29	12.11	2.59

По средней ошибке очков нейросеть точнее Elo на 1.88 очка на команду. По местам преимущество меньше — 0.14 позиции. Расчёт полезен для оценки общего уровня команд и состава верхней части таблицы. Выбор чемпиона и порядок в плотной середине остаются заметно менее точными. Эти результаты относятся к одному тестовому сезону.

Турнирные таблицы сезона 2019/20

Строки расположены по фактическому месту. «Расчёт» — сумма ожидаемых очков, Δ очков — факт минус расчёт, Δ мест — расчётное место минус фактическое. В таблице Лиги 1 очки показаны за сыгранные матчи, а расчётные места определяются по очкам за матч.

АПЛ

Место	Команда	Очки	Расчёт	Δ очков	Расчётное место	Δ мест
1	Liverpool	99	83.90	+15.10	2	+1
2	Manchester City	81	86.70	-5.70	1	-1
3	Manchester United	66	64.84	+1.16	4	+1
4	Chelsea	66	68.30	-2.30	3	-1
5	Leicester	62	59.87	+2.13	5	+0
6	Tottenham	59	52.91	+6.09	9	+3
7	Wolverhampton Wanderers	59	56.18	+2.82	6	-1
8	Arsenal	56	54.77	+1.23	8	+0
9	Sheffield United	54	45.98	+8.02	12	+3
10	Burnley	54	47.12	+6.88	11	+1
11	Southampton	52	48.13	+3.87	10	-1
12	Everton	49	55.09	-6.09	7	-5
13	Newcastle United	44	43.38	+0.62	14	+1
14	Crystal Palace	43	43.71	-0.71	13	-1
15	Brighton	41	42.64	-1.64	16	+1
16	West Ham	39	42.71	-3.71	15	-1
17	Aston Villa	35	33.03	+1.97	20	+3
18	Bournemouth	34	42.19	-8.19	17	-1
19	Watford	34	41.65	-7.65	18	-1
20	Norwich	21	35.05	-14.05	19	-1

Бундеслига

Место	Команда	Очки	Расчёт	Δ очков	Расчётное место	Δ мест
1	Bayern Munich	82	79.15	+2.85	1	+0
2	Borussia Dortmund	69	63.45	+5.55	3	+1
3	RasenBallsport Leipzig	66	68.02	-2.02	2	-1
4	Borussia M.Gladbach	65	56.37	+8.63	5	+1
5	Bayer Leverkusen	63	56.49	+6.51	4	-1
6	Hoffenheim	52	45.50	+6.50	7	+1
7	Wolfsburg	49	51.39	-2.39	6	-1
8	Freiburg	48	39.86	+8.14	11	+3
9	Eintracht Frankfurt	45	45.28	-0.28	8	-1
10	Hertha Berlin	41	41.59	-0.59	10	+0
11	Union Berlin	41	35.43	+5.57	16	+5
12	Schalke 04	39	42.34	-3.34	9	-3
13	Mainz 05	37	39.04	-2.04	12	-1
14	FC Cologne	36	38.98	-2.98	13	-1
15	Augsburg	36	37.02	-1.02	15	+0
16	Werder Bremen	31	38.73	-7.73	14	-2
17	Fortuna Duesseldorf	30	34.09	-4.09	17	+0
18	Paderborn	20	31.85	-11.85	18	+0

Ла Лига

Место	Команда	Очки	Расчёт	Δ очков	Расчётное место	Δ мест
1	Real Madrid	87	74.85	+12.15	2	+1
2	Barcelona	82	77.61	+4.39	1	-1
3	Atletico Madrid	70	68.53	+1.47	3	+0
4	Sevilla	70	63.68	+6.32	4	+0
5	Villarreal	60	59.12	+0.88	5	+0
6	Real Sociedad	56	54.59	+1.41	7	+1
7	Granada	56	44.34	+11.66	15	+8
8	Getafe	54	56.97	-2.97	6	-2
9	Valencia	53	53.23	-0.23	8	-1
10	Osasuna	52	42.82	+9.18	18	+8
11	Athletic Club	51	50.60	+0.40	9	-2
12	Levante	49	47.07	+1.93	11	-1
13	Real Valladolid	42	41.54	+0.46	19	+6
14	Eibar	42	46.17	-4.17	12	-2
15	Real Betis	41	47.51	-6.51	10	-5
16	Alaves	39	43.08	-4.08	16	+0
17	Celta Vigo	37	45.33	-8.33	14	-3
18	Leganes	36	43.01	-7.01	17	-1
19	Mallorca	33	37.76	-4.76	20	+1
20	Espanyol	25	45.83	-20.83	13	-7

Серия А

Место	Команда	Очки	Расчёт	Δ очков	Расчётное место	Δ мест
1	Juventus	83	76.18	+6.82	2	+1
2	Inter	82	74.12	+7.88	3	+1
3	Atalanta	78	77.07	+0.93	1	-2
4	Lazio	78	62.98	+15.02	6	+2
5	Roma	70	65.99	+4.01	5	+0
6	AC Milan	66	59.71	+6.29	7	+1
7	Napoli	62	66.10	-4.10	4	-3
8	Sassuolo	51	44.13	+6.87	12	+4
9	Verona	49	43.07	+5.93	16	+7
10	Fiorentina	49	49.32	-0.32	9	-1
11	Parma Calcio 1913	49	42.07	+6.93	17	+6
12	Bologna	47	52.35	-5.35	8	-4
13	Udinese	45	43.67	+1.33	13	+0
14	Cagliari	45	43.47	+1.53	15	+1
15	Sampdoria	42	45.81	-3.81	11	-4
16	Torino	40	46.41	-6.41	10	-6
17	Genoa	39	43.54	-4.54	14	-3
18	Lecce	35	36.37	-1.37	20	+2
19	Brescia	25	37.06	-12.06	19	+0
20	SPAL 2013	20	37.64	-17.64	18	-2

Лига 1

Место	Команда	Матчи	Очки	Расчёт	Δ очков	Расчётное место	Δ мест
1	Paris Saint Germain	27	68	61.02	+6.98	1	+0
2	Marseille	28	56	44.80	+11.20	3	+1
3	Rennes	28	50	40.80	+9.20	6	+3
4	Lille	28	49	44.35	+4.65	4	+0
5	Nice	28	41	38.05	+2.95	9	+4
6	Reims	28	41	41.00	-0.00	5	-1
7	Lyon	28	40	48.91	-8.91	2	-5
8	Montpellier	28	40	40.40	-0.40	7	-1
9	Monaco	28	40	39.51	+0.49	8	-1
10	Strasbourg	27	38	36.23	+1.77	11	+1
11	Angers	28	39	37.38	+1.62	12	+1
12	Bordeaux	28	37	33.33	+3.67	14	+2
13	Nantes	28	37	37.71	-0.71	10	-3
14	Brest	28	34	30.57	+3.43	17	+3
15	Metz	28	34	29.94	+4.06	19	+4
16	Dijon	28	30	30.46	-0.46	18	+2
17	Saint-Etienne	28	30	37.22	-7.22	13	-4
18	Nimes	28	27	32.15	-5.15	15	-3
19	Amiens	28	23	30.86	-7.86	16	-3
20	Toulouse	28	13	29.82	-16.82	20	+0

Полные данные доступны в Excel[2] и CSV[3]. Сводные ошибки по лигам сохранены в отдельной таблице[4].

Выводы

Log loss 0.99187, Brier 0.59131, accuracy 51.4% на 1,725 матчах сезона 2019/20. Средняя ошибка суммы предматчевых ожиданий — 5.18 очка на команду, расчётного места — 1.96 позиции. В пределах двух мест оказались 68 из 98 команд. Парные интервалы показывают преимущество нейросети над частотным, пуассоновским и Elo-ориентирами на этом наборе матчей. Усреднение двух небольших сетей и последовательное расширение обучения позволяют использовать историю нескольких сезонов при сохранении временного порядка.

Оценка ретроспективная: итоговая конфигурация зафиксирована с учётом результатов на этом архиве. Независимое подтверждение требует следующего сезона. Для дальнейшего повышения качества полезны составы, травмы и условия проведения встреч; текущие признаки ограничены прошлой командной статистикой.

Словарь данных

Поле	Значение и доступность
match_id, date, league, season	Ключ, дата, лига, год начала сезона
home_id, away_id, home, away	Команды; ключи для истории, не входы сети
home_goals, away_goals, home_xg, away_xg	Итог текущего матча; используются только после его даты
target	0=П1, 1=Х, 2=П2
f_home/away_*_5, *_10	Средние последних 5/10 предыдущих матчей
f_home/away_history	Число предыдущих матчей, ограниченное 100

[2] Файл в исходном проекте:`reports/tables/final_team_points.xlsx`
[3] Файл в исходном проекте:`reports/tables/final_team_points.csv`
[4] Файл в исходном проекте:`reports/tables/final_team_error_summary.csv`

Поле	Значение и доступность
f_home/away_rest	Дни отдыха, ограниченные 60; неизвестно при отсутствии истории
f_home/away_matches_14d	Число прошлых игр за 14 дней
f_home/away_venue_xgf/xga	Сглаженный прошлый xG дома/в гостях
f_elo_difference	Разность рейтингов с домашней поправкой
f_poisson_home/away	Интенсивности голов простого ориентира
c_league	Категория лиги
p_neural_0/1/2	Вероятности П1/Х/П2 итоговой модели
split	train, validation, calibration, test

В `final_team_points.csv` одна строка соответствует команде в сезоне.

Поле	Значение
matches, points	Сыгранные матчи и набранные очки
expected	Сумма 3 × P(победа) + P(ничья) по матчам команды
difference, absolute_error	Факт минус ожидание и модуль этой разницы
actual_position	Итоговое место из справочной таблицы RSSSF
predicted_position	Место по ожидаемым очкам, для Лиги 1 по очкам за матч
position_difference	Расчётное место минус фактическое, плюс означает финиш выше расчёта
absolute_position_error	Модуль отклонения места
points_per_match, expected_per_match	Фактические и ожидаемые очки на матч
ranking_basis	points или points_per_match, правило сортировки

В `final_team_error_summary.csv` находятся ошибки по лигам и общая строка `all`. MAE, RMSE, смещение и стандартное отклонение выражены в очках, variance — в очках². `within_5_points`, `within_10_points`, `exact_positions`, `within_2_positions` содержат число команд. `mae_per_match` — среднее по командам от абсолютного отклонения сезонных очков, делённого на число матчей команды. Показатели `position_*` выражены в местах.

`forecast.w/d/l` из источника исключены. Префиксы `f_` и `c_` определяют список входов; `b_` и `p_` содержат результаты ориентиров и не попадают в подготовку входов автоматически.

Итоговые прогнозы хранятся в `reports/final_predictions.csv`. Метрики и параметры вывода — в `reports/final_metrics.json`, таблицы — в файлах с префиксом `final_` папки `reports/tables`.

Источники

- Understat — первоначальный поставщик xG и результатов.
- Markjwilkins/Understat, коммит `4b42df35599f574c08ac65caacaf7975ed5fa138`: 30 таблиц в папке Matches, пять лиг за 2014–2019 годы начала сезона. Данные загружаются из публичного зеркала.
- Keras: сохранение модели.
- TensorFlow Dense.

Получено 2 ноября 2026 года. Адреса и SHA-256 каждого CSV закреплены в `config/sources.json`. В зеркале не обнаружена отдельная лицензия на распространение данных: в Git и ZIP включён загрузчик, а исходные CSV и построчные промежуточные данные остаются локальными. Выгрузка содержит поздний снимок данных; историю исправлений поставщика проверить по нему невозможно.

- Hyndman и Athanasopoulos. Временная кросс-валидация.
- Итоговые таблицы RSSSF за 2019/20 — Англия, Германия, Испания, Италия, Франция. Справочник `config/standings_2019_20.csv` содержит итоговые места, число матчей, очки и адрес источника для каждой команды. Проверено 4 ноября 2026 года.

Воспроизведение

Python 3.12. Команды выполняются из корня проекта.

```
python -m pip install -e ".[dev]"
python -m match_forecast analyze
python -m match_forecast.final_report
```

Ноутбук `notebooks/analysis.ipynb` повторяет подготовку данных, расчёт итоговых прогнозов, метрик и графиков. Выбранная схема записана в `config/report_model.json`. Сохранённые веса и параметры преобразования находятся в `models`; версии и контрольные суммы источников — в `config/sources.json`.