АНАЛИТИЧЕСКИЙ ОТЧЁТ

Вероятности исходов футбольных матчей

Содержание

Задача и время прогноза 2

Источник и подготовка данных 2

Лиги и домашнее преимущество 2

Признаки до начала матча 3

Нейросеть и расширяющееся окно 3

Простые ориентиры 4

Качество прогноза 4

Вероятности и ошибки исходов 5

Неопределённость результата 6

Перерыв в сезоне 2019/20 6

Прогнозы матчей и ожидаемые очки 6

Выводы 7

Словарь данных 7

Источники 7

Воспроизведение 8

Нейросеть TensorFlow/Keras прогнозирует победу хозяев, ничью и победу гостей до начала матча. Используется архив Understat по пяти лигам за 2014/15–2019/20. Модель ежегодно обучается заново на всей завершённой истории.

Задача и время прогноза

Для каждой встречи нужны три вероятности, сумма которых равна единице. Они позволяют учитывать неопределённость исхода и рассчитывать ожидаемые очки команд. Прогноз строится на начало календарного дня. Результаты встреч этого дня добавляются в историю со следующей даты.

Единица наблюдения — сыгранный матч. Целевая переменная равна 0 при победе хозяев, 1 при ничьей и 2 при победе гостей. Все матчи одного дня используют одинаковую границу доступной информации.

Источник и подготовка данных

Первичный поставщик — Understat; таблицы получены из закреплённой версии публичного зеркала Mark Wilkins. В анализ входят 10,855 сыгранных матчей АПЛ, Ла Лиги, Бундеслиги, Серии А и Лиги 1. Период простирается с 2014-08-08 по 2020-08-02.

Исключена 101 строка без сыгранного результата, преимущественно отменённые встречи Лиги 1. Проверяются уникальность ID, конечные неотрицательные голы и xG, даты и состав лиг. В архиве 465 матчей хотя бы с одной командой, имеющей менее пяти предыдущих игр в доступной истории.

Текущие голы и xG используются после завершения матча. Готовые `forecast.w/d/l` поставщика исключены из входов, поскольку их доступность до игры не подтверждена. Даты читаются в календарной шкале источника. Архив является поздним снимком; историю исправлений xG и дат по нему восстановить нельзя.

Лиги и домашнее преимущество

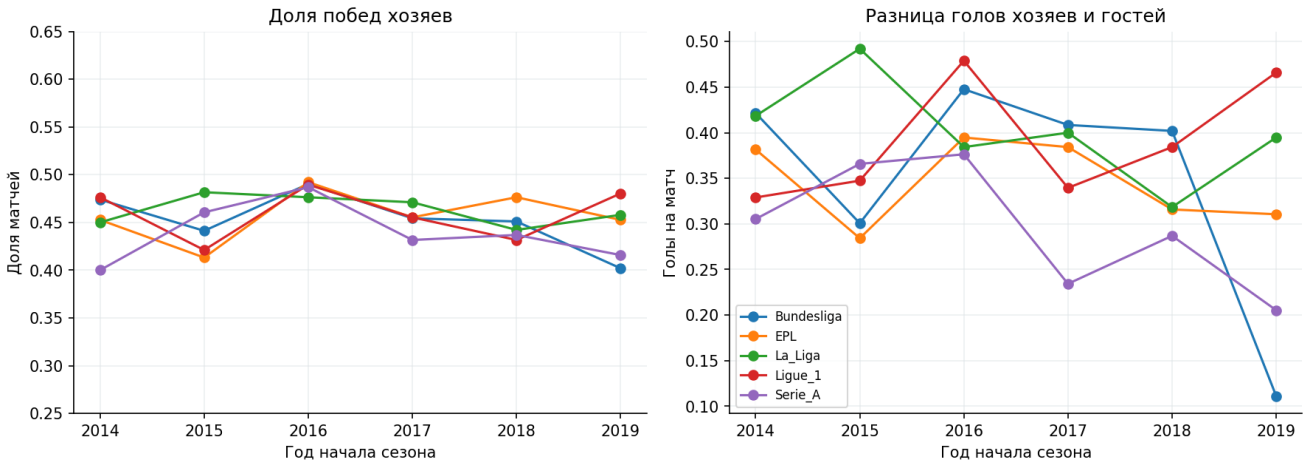


Рис. 1: Домашнее преимущество

Сравниваются доля домашних побед и разница голов хозяев и гостей на матч. Показатели рассчитываются отдельно для лиги и сезона. Такое представление учитывает разные размеры чемпионатов. Сезон Лиги 1 2019/20 завершён досрочно; для него учитываются сыгранные встречи.

Графики описывают результативность дома и в гостях. На межсезонные различия влияют состав клубов, календарь и условия проведения матчей. Все агрегаты доступны в таблице лиг и сезонов[1].

[1] Файл в исходном проекте: `reports/tables/league_seasons.csv`

Признаки до начала матча

Для хозяев и гостей используются средние голов, xG за и против и очков за последние 5 и 10 встреч. Дополняют их число дней отдыха, число матчей за 14 дней, домашняя и гостевая история и рейтинг Elo. Число предыдущих встреч ограничено 100, отдых — 60 днями. Отдельно сохраняется доступность истории.

История привязана к лиге и ID клуба. Названия и идентификаторы служат соединению записей; лига входит в сеть как категория. В матрице нет будущих итогов сезона и результата прогнозируемой игры. Тесты изменяют текущие и будущие результаты и проверяют неизменность более ранних признаков.

Пустая история заполняется медианами обучения и получает индикатор пропуска. Масштабы числовых признаков и категории лиг определяются заново внутри каждого обучающего окна. Для нового клуба Elo начинается с 1500.

Нейросеть и расширяющееся окно

Итоговая модель усредняет вероятности двух сетей с одинаковыми скрытыми слоями 32/16 и разными seed — 20261104 и 20261121. Используются ReLU, L2=0.005 и Dropout=0.2. Три выходных логита преобразуются softmax в П1/Х/П2. Adam работает с learning rate 0.001, размер пакета 256, функция потерь — cross-entropy.

Перед началом сезона последний завершённый сезон временно выделяется для ранней остановки. На более ранних сезонах оцениваются преобразования и веса; остановка отслеживает log loss, максимум 100 эпох, patience=10. Затем сеть и преобразования обучаются с нуля на всей доступной истории с выбранным числом эпох. Две сети получают собственное число эпох.

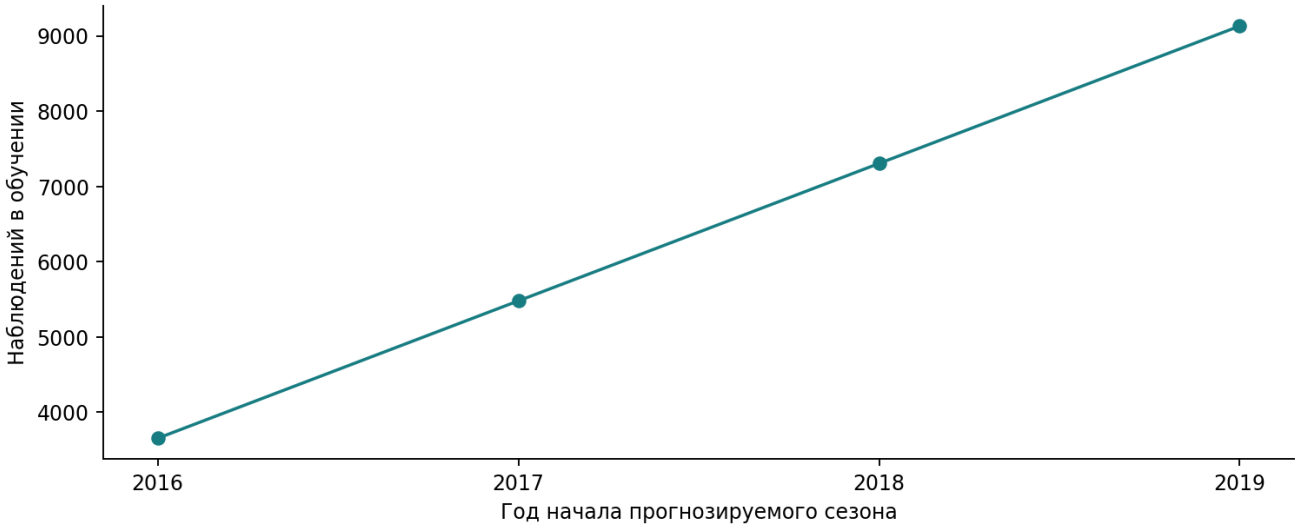


Рис. 2: История обучения

Период	Обучение	Прогноз	Эпохи двух сетей
2016	3652	1826	26 / 25
2017	5478	1826	51 / 26
2018	7304	1826	23 / 46
2019	9130	1725	28 / 12

Проверочные сезоны 2017/18 и 2018/19 используют только более ранние результаты. Для оценки 2019/20 сеть обучена на 9 130 матчах сезонов 2014/15–2018/19. Во время прогнозируемого сезона веса фиксированы, а входная история команд пополняется после завершённых дней. Вероятности берутся из среднего softmax двух сетей.

Простые ориентиры

Постоянный прогноз использует частоты П1/Х/П2. Elo обновляется после игрового дня с K=20 и домашней поправкой 70. На границе сезона сохраняется 75% отклонения рейтинга от 1500. Частоты исходов и параметр ничьей Elo оценены на сезонах 2014/15–2016/17; сам рейтинг продолжает обновляться по завершённым матчам.

Пуассоновский ориентир берёт геометрическое среднее прошлого xG атаки команды и xG обороны соперника с учётом дома/выезда. Командные средние сглаживаются пятью условными матчами к прошлому среднему лиги. Начальная лига содержит 20 условных матчей с 1.4 домашнего и 1.1 гостевого xG. Интенсивности ограничены диапазоном [0.1; 6], счёт перебирается от 0 до 30 голов, затем вероятности нормируются. Голы команд в этом ориентире предполагаются независимыми.

Качество прогноза

Основная метрика — log loss. Brier равен средней сумме квадратов ошибок трёх вероятностей. Accuracy — доля матчей, в которых наиболее вероятный исход совпал с фактом. Все модели оцениваются на одинаковых 1,725 матчах.

Модель	Матчи	Log loss	Brier	Accuracy
Частоты исходов	1725	1.07046	0.64767	0.44116
Elo	1725	1.00428	0.60004	0.51710
Пуассон по xG	1725	1.02579	0.61521	0.48986
Нейросеть	1725	0.99187	0.59131	0.51420

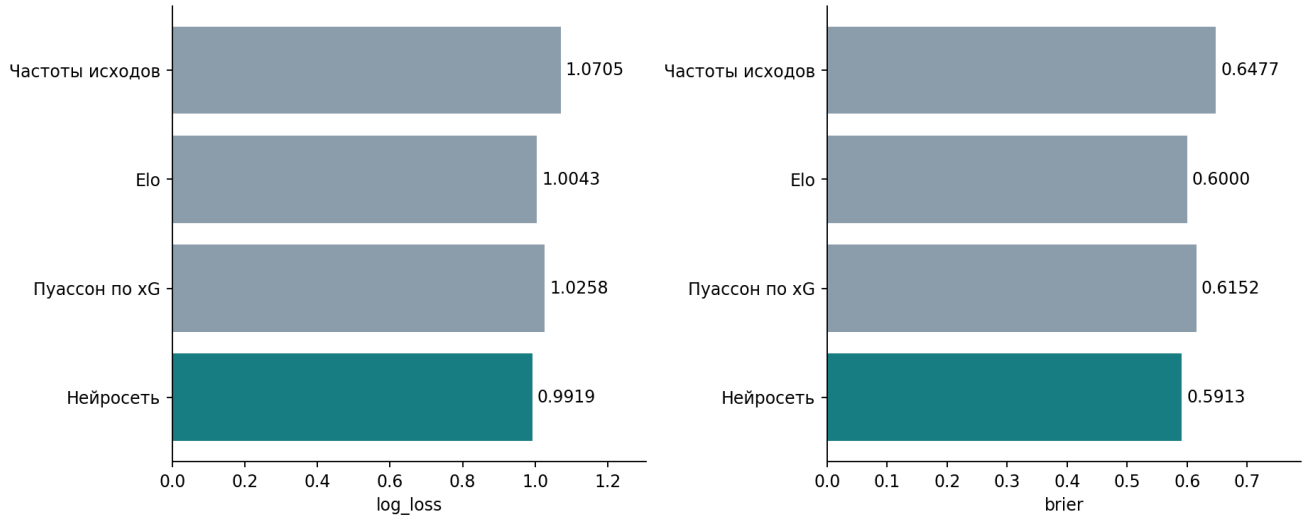


Рис. 3: Сравнение с ориентирами

Лига	Матчи	Log loss	Brier	Accuracy
Бундеслига	306	0.99556	0.59439	0.50654
АПЛ	380	0.97839	0.58139	0.51053
Ла Лига	380	1.00876	0.60541	0.49737
Лига 1	279	1.00092	0.59925	0.50538
Серия А	380	0.97882	0.57882	0.54737

Разрезы показывают качество отдельно по каждой лиге. При сравнении важны число матчей, баланс исходов и полнота истории новых команд.

Вероятности и ошибки исходов

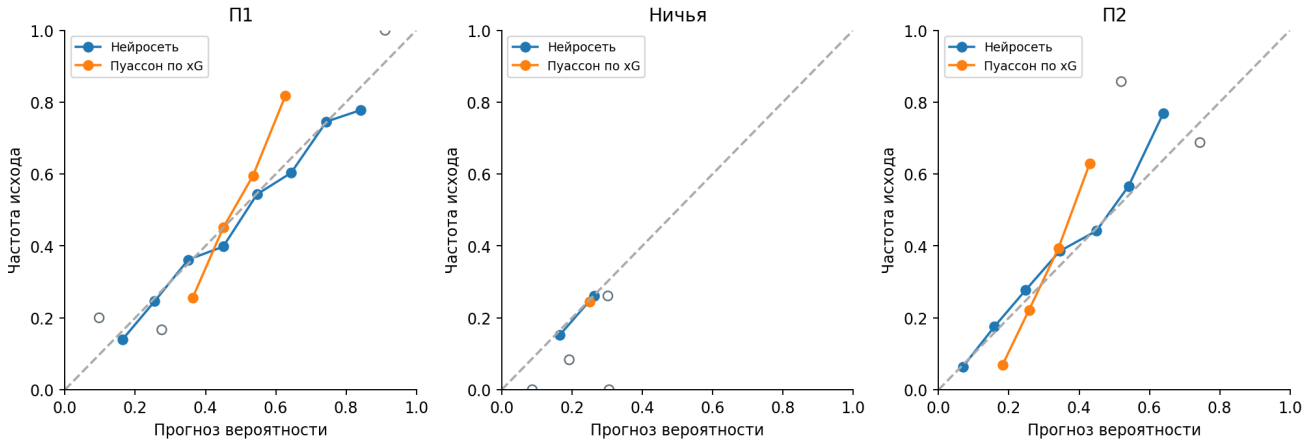


Рис. 4: Вероятности и частоты

Для каждого исхода прогнозы разбиты на интервалы шириной 0.1. Средняя вероятность сопоставлена с долей фактических исходов. Полые точки обозначают интервалы с менее чем 30 матчами. Это проверка вероятностей итоговой сети.

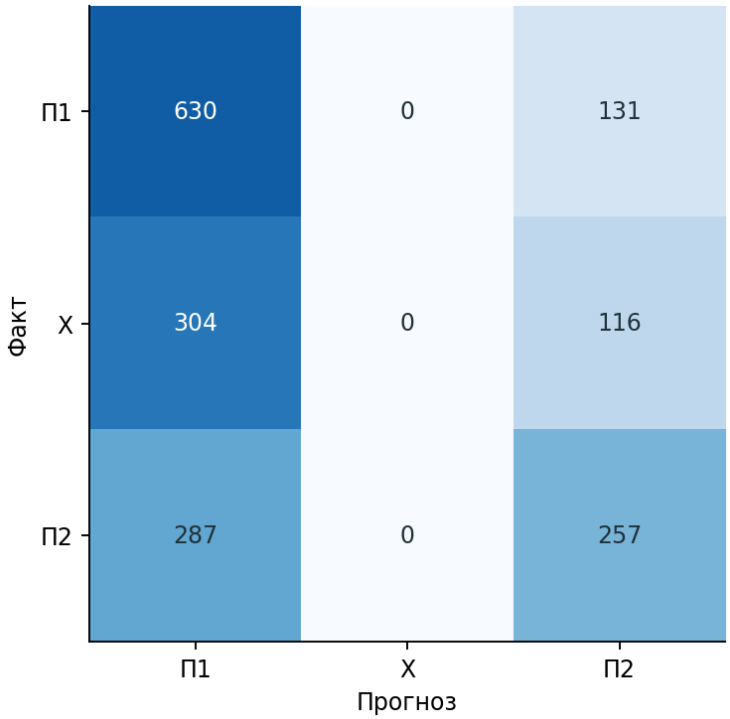


Рис. 5: Распределение ошибок

Ничья оказалась наиболее вероятным исходом в 0 матчах из 1725. Матрица отражает решение по максимуму вероятности; log loss использует весь вектор и чувствителен к уверенности прогноза.

Неопределённость результата

Ориентир	Разница log loss	Нижняя 95%	Верхняя 95%
Частоты исходов	-0.07859	-0.09533	-0.06216
Elo	-0.01241	-0.02066	-0.00375
Пуассон по xG	-0.03392	-0.04459	-0.02368

Разница равна log loss нейросети минус log loss ориентира. 95% интервалы рассчитаны 3 000 повторами парного бутстрэпа по календарным неделям. Все встречи одной недели остаются в одном блоке. Связи повторных игр клубов между неделями могут сохраняться; поправка на несколько сравнений не вводилась.

Перерыв в сезоне 2019/20

Модель	Период	Матчи	Log loss	Brier
Elo	До перерыва	1317	1.00945	0.60380
Elo	После перерыва	408	0.98757	0.58791
Пуассон по xG	До перерыва	1317	1.02911	0.61767
Пуассон по xG	После перерыва	408	1.01508	0.60725
Нейросеть	До перерыва	1317	1.00026	0.59746
Нейросеть	После перерыва	408	0.96477	0.57146

Первая группа включает даты до 15 марта 2020 года, вторая — с 15 мая. Лига 1 сезон не возобновила, поэтому состав лиг во второй группе отличается. Разрез показывает устойчивость ошибок в двух частях календаря; для объяснения различий потребовались бы посещаемость, составы и травмы.

Прогнозы матчей и ожидаемые очки

Дата	Хозяева	Гости	П1	Ничья	П2
2020-08-01	AC Milan	Cagliari	0.753	0.168	0.079
2020-08-01	Brescia	Sampdoria	0.361	0.284	0.355
2020-08-01	Juventus	Roma	0.622	0.230	0.148
2020-08-02	SPAL 2013	Fiorentina	0.319	0.273	0.408
2020-08-02	Sassuolo	Udinese	0.483	0.281	0.236
2020-08-02	Bologna	Torino	0.455	0.291	0.254
2020-08-02	Genoa	Verona	0.410	0.292	0.298
2020-08-02	Lecce	Parma Calcio 1913	0.488	0.269	0.243

Показаны исторические прогнозы последних матчей архива. Например, вероятность 0.6 означает оценку 60% для соответствующего исхода при доступной модели информации. Для каждой команды ожидаемые очки в матче равны $3 \times$ P(победа) + P(ничья).

Команда	Матчи	Очки	Ожидание	Разница
Espanyol	38	25	45.83	-20.83
SPAL 2013	38	20	37.64	-17.64
Toulouse	28	13	29.82	-16.82
Liverpool	38	99	83.90	15.10
Lazio	38	78	62.98	15.02
Norwich	38	21	35.05	-14.05
Real Madrid	38	87	74.85	12.15
Brescia	38	25	37.06	-12.06

В таблице восемь наибольших абсолютных отклонений фактических очков от суммы предматчевых ожиданий. Размер выборки ограничен матчами тестового сезона. Такое отклонение может отражать неожиданные результаты и ошибки прогноза. Полная таблица команд[2] содержит все клубы.

Выводы

Log loss 0.99187, Brier 0.59131, accuracy 51.4% на 1,725 матчах сезона 2019/20. Парные интервалы показывают преимущество нейросети над частотным, пуассоновским и Elo-ориентирами на этом наборе матчей. Усреднение двух небольших сетей и последовательное расширение обучения позволяют использовать историю нескольких сезонов при сохранении временного порядка.

Оценка ретроспективная: итоговая конфигурация зафиксирована с учётом результатов на этом архиве. Независимое подтверждение требует следующего сезона. Для дальнейшего повышения качества полезны составы, травмы и условия проведения встреч; текущие признаки ограничены прошлой командной статистикой.

Словарь данных

Поле	Значение и доступность
match_id, date, league, season	Ключ, дата, лига, год начала сезона
home_id, away_id, home, away	Команды; ключи для истории, не входы сети
home_goals, away_goals, home_xg, away_xg	Итог текущего матча; используются только после его даты
target	0=П1, 1=Х, 2=П2
f_home/away_*_5, *_10	Средние последних 5/10 предыдущих матчей
f_home/away_history	Число предыдущих матчей, ограниченное 100
f_home/away_rest	Дни отдыха, ограниченные 60; неизвестно при отсутствии истории
f_home/away_matches_14d	Число прошлых игр за 14 дней
f_home/away_venue_xgf/xga	Сглаженный прошлый xG дома/в гостях
f_elo_difference	Разность рейтингов с домашней поправкой
f_poisson_home/away	Интенсивности голов простого ориентира
c_league	Категория лиги
p_neural_0/1/2	Вероятности П1/Х/П2 итоговой модели
split	train, validation, calibration, test

`forecast.w/d/l` из источника исключены. Префиксы `f_` и `c_` определяют список входов; `b_` и `p_` содержат результаты ориентиров и не попадают в подготовку входов автоматически.

Итоговые прогнозы хранятся в `reports/final_predictions.csv`. Метрики и параметры вывода — в `reports/final_metrics.json`, таблицы — в файлах с префиксом `final_` папки `reports/tables`.

Источники

- Understat — первоначальный поставщик xG и результатов.
- Markjwilkins/Understat, коммит `4b42df35599f574c08ac65caacaf7975ed5fa138`: 30 таблиц в папке Matches, пять лиг за 2014–2019 годы начала сезона. Данные загружаются из публичного зеркала.
- Keras: сохранение модели.
- TensorFlow Dense.

Получено 2 ноября 2026 года. Адреса и SHA-256 каждого CSV закреплены в `config/sources.json`. В зеркале не обнаружена отдельная лицензия на распространение данных: в Git и ZIP включён загруз-

[2] Файл в исходном проекте:`reports/tables/final_team_points.csv`

чик, а исходные CSV и построчные промежуточные данные остаются локальными. Выгрузка содержит поздний снимок данных; историю исправлений поставщика проверить по нему невозможно.

- Hyndman и Athanasopoulos. Временная кросс-валидация.

Воспроизведение

Python 3.12. Команды выполняются из корня проекта.

```
python -m pip install -e ".[dev]"
python -m match_forecast analyze
python -m match_forecast.final_report
```

Ноутбук `notebooks/analysis.ipynb` повторяет подготовку данных, расчёт итоговых прогнозов, метрик и графиков. Выбранная схема записана в `config/report_model.json`. Сохранённые веса и параметры преобразования находятся в `models`; версии и контрольные суммы источников — в `config/sources.json`.